

WSTĘP DO SZTUCZNEJ INTELIGENCJI

Ćwiczenie 2 – Algorytm Ewolucyjny

MICHAŁ MIZIA 331407

SPIS TREŚCI

Wstęp.....	3
Wybór metod	4
Wnioski	5

Wstęp

Ewolucja kodu:

Kod algorytmu genetycznego przeszedł serię przemian, ostatecznie powstały 2 pliki:

- ga_tournament.py
- ga_roulette.py

Na początku ciężko było selekcją ruletkową osiągnąć wynik zbliżony do selekcji turniejowej. Wypisywanie wszystkich członków populacji pod koniec pozwalało stwierdzić że algorytm za szybko schodzi do minimum lokalnego i nie potrafi z niego wyjść. Np. przy populacji 200 po 100 iteracjach wszyscy członkowie mieli dokładnie tą samą ścieżkę.

Zmiany jakie pozwoliły to naprawić:

- Zmiana obliczeń fitness z $1/(dł_trasy)$ na $1/(dł_trasy - min_eval + 1e-6)$, to skutkowało w większej losowości przy wyborze osobników.
- Zmiana selekcji ruletkowej z całej populacji na połowę populacji, następnie gdy wybierzemy nową populację o wielkości 0,5 starej, przechodzimy do funkcji crossover która zwraca populację do starej wielkości. Dla każdego osobnika albo dobiera mu losową parę w wypadku krzyżowania, albo wpisuje jego i dodatkowego osobnika do populacji.

```
def apply_crossovers(population: List[Member], cross_chance: float) -> List[Member]:
    new_population = []
    for i in range(0, len(population)):
        parent1 = population[i]
        parent2 = population[np.random.choice(len(population))]
        if np.random.random() < cross_chance:
            # Perform crossover and get two offspring
            offspring1, offspring2 = crossover(parent1, parent2)
            new_population.extend([offspring1, offspring2])
        else:
            # add copies of parents to new population
            new_population.extend([parent1, parent2])
    return new_population
```

- Do tego między selekcją turniejową a ruletkową zaszło dużo zmian które pozwoliły na osiągnięcie w miarę sensownych wyników.

Wybór metod

- Krzyżowanie

Jako metoda krzyżowania zostało wybrane krzyżowanie członków po kolei z innym losowym członkiem populacji przy użyciu krzyżowania OX 2 punktowego z prawdopodobieństwem 0.9

- Mutacja

Mutacja jest wykonywana przez losową zamianę 2 miast z prawdopodobieństwem 0,05.

- Selekcja

Selekcja ruletkowa przy użyciu wartości $\text{fitness} = 1/(\text{dł_trasy} - \text{min_eval} + 1e-6)$ oraz znormalizowaniu wartości tak żeby suma wszystkich wartości fitness wynosiła 1

Wnioski

Średnia najlepsza ewaluacja, najlepsza ewaluacja i dewiacja standardowa dla grupy 5 eksperymentów przy różnych populacjach, miasta to Warszawa i Rzeszów; prawdopodobieństwo mutacji => 0,05; prawdopodobieństwo krzyżowania => 0,9; maksymalna ilość iteracji => 200;

Population Size	Best Eval	Avg Best Eval	Std Dev
50	8806.705999999998	9280.0948	421.97132088775976
100	7656.2080000000005	8253.6018	645.352515098036
150	7187.010000000001	7568.591399999999	444.2416054394718
200	6791.5999999999985	7349.1291999999985	415.4400571728252
250	7042.079000000003	7427.818400000001	339.91751764661973
300	6923.763999999999	7459.1154	334.44158317565746
350	6553.179000000001	7115.272800000001	473.55973911024205
400	6410.528999999998	6739.8726	294.38306316607446
450	6142.025	6784.4396	546.2612543388368

Widzimy że wraz ze wzrostem wielkości populacji długość najkrótszej trasy spada, prawdopodobnie spadałaby dalej gdyby zwiększać ilość populacji do wartości około 5500km (najlepsza wartość jaką udało się uzyskać).

Prawdopodobnie jest tak ponieważ skuteczność algorytmu jest ograniczona przez to jak szybko skonwertuje on do lokalnego minimum a przy większych populacjach konwertuje wolniej.

Poniżej mapa trasy Warszawa – Rzeszów o długości 6100km. Każdą znaną trasę można na bieżąco wizualizować przy pomocy wizualizatora. Generuje on plik .html z punktami z map google który następnie należy odpalić przy pomocy rozszerzenia Live Server

